

Stock Analysis Pipeline

Spécification Fonctionnelle v1.1

Projet:	Stock Analysis Pipeline
Version:	1.1
Nature:	Testable, auditable, vérifiable
Statut:	Review externe complétée (Codex + Hermes)
Auteurs:	Hermes + Codex CLI
Date:	2026-05-19

Pipeline d'analyse fondamentale automatisé pour investisseurs particuliers. Analyse en 9 étapes : collecte de données financières multi-sources (yfinance, Finnhub, EDGAR, Seeking Alpha, Tavily, Alpha Vantage), scoring BUY/HOLD/SELL sur 40 points répartis en 6 catégories, génération de PDF deep-dive professionnel (10-14 pages, format Nami-grade) et dossier ZIP auditable. Support multilingue EN/JP/bilingual. Déploiement WSL2 + Cloudflare Tunnel avec health check et auto-recovery.

1. Périmètre et définitions

1.1 Acteurs

ID	Acteur	Description	Compétences
ACT-001	Investisseur pri	Utilisateur unique, inves	Analyse financière
ACT-002	Auditeur externe	Vérifie la conformité des	Contrôle qualité
ACT-003	Veilleur automat	Cron jobs Hermes de monit	Aucune (système)

1.2 Périmètre fonctionnel — Inclus

ID	Élément	Justification
IN-001	Analyse fondamentale par ticker	Cœur du produit
IN-002	Scoring BUY/HOLD/SELL (40 pts, 6	Décision d'investissement
IN-003	PDF deep-dive formaté (10-14p, R	Livrable principal
IN-004	Dossier ZIP téléchargeable (PDF	Auditabilité
IN-005	Sélection langue EN/JP/bilingual	Usage international
IN-006	Batch analysis API (upload CSV)	Efficacité
IN-007	Feedback utilisateur horodaté av	Amélioration continue
IN-008	Collecte IR sites (dates earning	Enrichissement données
IN-009	Health check + monitoring + auto	Production

1.3 Hors périmètre

ID	Élément	Raison
OUT-001	Trading automatisé	Analyse seulement, pas exécutio
OUT-002	Données temps réel (streamin	Fondamentale uniquement
OUT-003	Screening de marché (scanner	Analyse individuelle par ticker
OUT-004	API publique / multi-utilisa	Usage personnel
OUT-005	Backtesting de stratégies	Projet séparé (hedge-fund-local

2. Exigences fonctionnelles

UC-001 — Analyser un ticker

Acteur : ACT-001 | Déclencheur : Saisie ticker + clic « Analyze » | Postcondition : PDF + ZIP disponibles

Scénario nominal (AC-001)

Given le backend est actif sur le port 8780, and les 6 API externes (yfinance, FintHub, EDGAR, Seeking Alpha, TaviLy, Alpha Vantage) sont accessibles, and le ticker AAPL est valide. When l'utilisateur saisit « AAPL » et clique « Analyze ». Then le pipeline exécute les 9 étapes séquentiellement, and un PDF deep-dive ≥ 10 pages est généré, and le score est affiché avec BUY/HOLD/SELL, and le bouton « Download ZIP » est actif.

Scénario ticker invalide (AC-002)

Given le backend est actif. When l'utilisateur saisit « ZZZZYX ». Then le système retourne un message d'erreur dans les 30 secondes, and aucune analyse n'est stockée.

Scénario API source partiellement down (AC-003)

Given le backend est actif, and l'API Seeking Alpha est indisponible. When l'utilisateur analyse NVDA. Then les données encore disponibles sont collectées (≥ 3 sources), and les sections manquantes affichent « DONNÉE NON DISPONIBLE », and le score est calculé avec les sources disponibles.

UC-002 — Consulter le PDF deep-dive

Acteur : ACT-001 | Déclencheur : Clic « View Full Report » | Précondition : Analyse complète disponible

Scénario nominal (AC-004)

Given une analyse de NVDA est terminée. When l'utilisateur clique « View Full Report ». Then un PDF s'ouvre dans le navigateur, and le PDF contient les 5 sections majeures (Synthèse, Scoring, Finances, Management, Risques), and le header bar est dark (#2A2A2A), and les callout boxes bleues (#2563EB) sont visibles.

Scénario donnée manquante (AC-005)

Given l'analyse de TSLA est terminée, and le transcript Q3 est indisponible. When l'utilisateur ouvre le PDF. Then la section transcript affiche « DONNÉE NON DISPONIBLE », and aucune donnée n'est inventée.

UC-003 — Télécharger le dossier ZIP

Acteur : ACT-001 | Déclencheur : Clic « Download ZIP » | Précondition : Analyse complète disponible

Scénario nominal (AC-006)

Given une analyse de NVDA est terminée. When l'utilisateur clique « Download ZIP ». Then un fichier .zip est téléchargé, and le ZIP contient au minimum : deep_dive_report.pdf, analysis.json, sources.json.

UC-004 — Batch analysis

Acteur : ACT-001 | Déclencheur : Upload CSV + clic « Batch Analyze » | Précondition : CSV valide avec ≤ 10 tickers

Scénario nominal (AC-007)

Given un CSV contenant 3 tickers (AAPL, MSFT, GOOGL). When l'utilisateur uploade le CSV et lance le batch. Then les 3 tickers sont traités séquentiellement, and un job_id est retourné, and le statut est consultable via GET /api/batch/{job_id}/status.

UC-005 — Feedback et correction

Acteur : ACT-001 | Déclencheur : Envoi d'un feedback | Précondition : Une analyse existe pour le ticker

Scénario nominal (AC-008)

Given une analyse de NVDA avec score 32/40 est affichée. When l'utilisateur envoie un feedback « Score surévalué, PER trop bas ». Then le feedback est horodaté (timestamp + message), and la réanalyse prend en compte le feedback.

UC-006 — Health check système

Acteur : ACT-003 (Veilleur automatique) | Déclencheur : Toutes les 15 minutes | Précondition : Cron job actif

Scénario nominal (AC-009)

Given le backend tourne sur le port 8780. When le cron job appelle GET /api/health. Then le endpoint retourne 200 avec {"status":"healthy","uptime":<N>}, and si le code est ≠ 200, le script auto-recovery est déclenché.

3. Pipeline d'analyse (9 étapes)

Le pipeline exécute 9 étapes séquentielles pour chaque ticker. Chaque étape a des dépendances de sources documentées et des fallbacks en cas d'indisponibilité.

Étape	ID	Module	Entrée	Sortie	Sources
1	PIP-001	Profil entrep	Ticker	CompanyProfi	yfinance
2	PIP-002	Collecte donn	Ticker, prof	FinancialDat	yfinance + Finnhu
3	PIP-003	Transcripts e	Ticker	Transcript[]	Seeking Alpha + T
4	PIP-004	Dépôts SEC	Ticker	SECFilings	EDGAR (edgartools
5	PIP-005	Analyse manag	Transcript[]	ManagementTo	LLM local/externe
6	PIP-006	Scoring (40 p	FinancialDat	Scoring	Calcul déterminis
7	PIP-007	Synthèse LLM	Toutes donné	DeepDiveRepo	DeepSeek / GPT

8	PIP-008	Génération PD	DeepDiveRepo	PDF (10-14p)	ReportLab
9	PIP-009	Archivage	PDF + source	ZIP + analys	Disque local

4. Schémas de données

4.1 Scoring (40 points)

Le scoring est calculé de manière déterministe à partir des données collectées. Aucun ML — règles explicites et auditable.

```
Scoring {
  total:          int ∈ [0, 40]
  financial_health: int ∈ [0, 10] // Dette, liquidité, cash flow
  growth:         int ∈ [0, 10] // Croissance CA, BNA
  valuation:      int ∈ [0, 8]   // PER, PEG, P/B, EV/EBITDA
  management:     int ∈ [0, 5]   // Tone analysis, insider trades
  moat:           int ∈ [0, 4]   // Marge, part de marché
  sentiment:      int ∈ [0, 3]   // News, analystes
  recommendation: enum["BUY", "HOLD", "SELL"]
  summary:        str (≤ 300 car.)
}
```

Seuils de recommandation

- BUY si total $\geq 28/40$
- HOLD si total entre 18 et 27/40
- SELL si total $< 18/40$
- INSUFFISANT si < 3 sources valides (pas de recommandation)

4.2 AnalysisResult

```
AnalysisResult {
  ticker:          str (1-5 car., uppercase)
  timestamp:       datetime (ISO 8601)
  status:          enum["running", "completed", "error"]
  score:           Scoring | null
  company_profile: dict
  financial_data:  FinancialData
  management_tone: ManagementTone | null
  risks:           RiskItem[] (≤ 20)
  valuation:       ValuationData
  sources:         Source[] (≥1, idéalement ≥5)
  pdf_path:        str | null
  dossier_path:    str | null
}
```

4.3 FinancialData

```
FinancialData {
  ticker:          str
  market_cap:      float | null    // USD
  revenue:         float | null    // TTM, USD
  net_income:      float | null
  eps:             float | null
  pe_ratio:        float | null
  peg_ratio:       float | null
  debt_to_equity:  float | null
  current_ratio:   float | null
  free_cash_flow:  float | null
  dividend_yield:  float | null
  revenue_growth_yoy: float | null // %
  gross_margin:    float | null    // %
  operating_margin: float | null    // %
}
```

4.4 Source

```
Source {
  type:    enum["yfinance","finnhub","edgar","seeking_alpha","tavily","alpha_vantage","web"]
  name:    str
  url:     str | null
  retrieved_at: datetime
  status:  enum["success","partial","failed"]
  data_points: int
}
```

4.5 DeepDiveReport

```
DeepDiveReport {
  ticker:      str
  quarter:     str          // "2025-Q3"
  generated_at: datetime
  sections:    Section[]
  metadata:    {model, tokens, cost_usd}
}
Section {
  title:      str
  content:    str          // Markdown → PDF
  sources:    str[]
  confidence: enum["high","medium","low"]
}
```

4.6 Feedback

```
Feedback {
  id:          str (UUID v4)
  ticker:      str
  timestamp:   datetime
  message:     str (≤ 2000 car.)
  correction_type: enum["score","data","missing","other"]
  processed:   bool
  applied_at:  datetime | null
}
```


Les 9 règles de gestion (BR-001 à BR-009) définissent le comportement attendu du pipeline dans toutes les conditions. Chaque règle est testable et vérifiable.

ID	Règle	Condition	Comportement attendu	Test
BR-001	Pas d'inventio	Source retourne	Afficher « DONNÉE N	
BR-002	Score min 3 so	< 3 sources vali	Score = null, « INS	
BR-003	PDF 5 sections	Génération PDF	Synthèse, Scoring,	
BR-004	Archivage obli	Analyse terminée	Sauvegarder dans an	
BR-005	Feedback → réa	Feedback non tra	Réanalyse après app	
BR-006	Rate limit cas	API retourne 429	Backoff 1s/2s/4s/8s	
BR-007	Timeout source	> 30s sans répon	Abandonner source,	
BR-008	Batch max 10 t	Batch upload	Rejeter si > 10 ave	
BR-009	Cache invalida	Cache > 1h ou re	Invalider et re-col	

6. Exigences non fonctionnelles

ID	Catégorie	Exigence	Cible	Mesure
NFR-001	Performance	Analyse complète	< 5 min	Chrono pipeline
NFR-002	Performance	Affichage PDF	< 2 s	Latence HTTP
NFR-003	Disponibili	API health	99% uptime	Health check (15 min
NFR-004	Sécurité	Auth write endpo	X-API-Key o	401 si absent
NFR-005	Fiabilité	Données manquant	Pas d'inven	Audit visuel PDF
NFR-006	Observabili	Logs structurés	Tous endpoi	JSON logs + timestam
NFR-007	Résilience	Rate limit APIs	Retry/backo	BR-006
NFR-008	Maintenabil	Couverture de te	≥ 60% pipel	pytest --cov
NFR-009	Sécurité	Secrets	.env unique	Scan pre-commit

7. Observabilité et audit

7.1 Événements de log

Chaque étape du pipeline émet un événement de log structuré avec niveau, champs et contexte. Les logs permettent de reconstituer l'intégralité du cycle de vie d'une analyse sans accéder au serveur.

Événement	Niveau	Champs	Trigger
pipeline.start	INFO	ticker, timestamp	Début analyse
pipeline.step	INFO	ticker, step (1-9), dura	Fin de chaque étape
pipeline.comple	INFO	ticker, total_ms, score,	Analyse terminée
pipeline.error	ERROR	ticker, step, error_type	Erreur étape
source.fetch	DEBUG	source_type, ticker, ms,	Après appel API
source.rate_lim	WARN	source_type, retry_after	API retourne 429
pdf.render	INFO	ticker, pages, size_kb,	PDF généré
api.request	INFO	method, path, status, ms	Chaque requête HTTP

7.2 Métriques exposées

Métrique	Endpoint	Type
Uptime secondes	/api/health	HealthResponse
Nombre sources par ticke	/api/traceability/{ticker}	JSON
Statut batch job	/api/batch/{job_id}/status	JSON
Recherches récentes	/api/admin/recent-searches	JSON

Stats recherche	/api/admin/search-stats	JSON
-----------------	-------------------------	------

8. Politique de confidentialité

Le pipeline utilise des LLM externes pour la synthèse narrative (étape 7). Les données transmises sont exclusivement des données financières publiques (ticker, chiffres trimestriels, transcripts publics). Aucune donnée personnelle (PII) n'est incluse dans les prompts.

ID	Principe	Implémentation
PR-001	Données transmises a	Uniquement données publiques (SEC, tra
PR-002	Pas de PII	Aucune donnée personnelle dans les pro
PR-003	Secrets API	Stockés dans .env, jamais transmis aux
PR-004	Logs	Ne contiennent pas les prompts LLM com
PR-005	Cache local	Stocké dans backend/cache/, effaçable
PR-006	Réversibilité	Toute analyse peut être régénérée (don
PR-007	Consentement	Usage personnel uniquement, pas de par

9. Rétention et restauration

9.1 Rétention des analyses

Artefact	Emplacement	Rétention
Analyse JSON	analyses/{ticker}_{timestamp}	Illimitée (disque lo
PDF deep-dive	analyses/{ticker}_{timestamp}	Illimitée
ZIP dossier complet	analyses/{ticker}_{timestamp}	Illimitée
Cache financier	backend/cache/	Volatil (invalidé su
Logs	backend/logs/	Rotation manuelle

9.2 Modes de défaillance et procédures de récupération

Le système est conçu pour la résilience : chaque mode de défaillance a une procédure de récupération documentée avec un délai cible.

Défaillance	Symptôme	Récupération	Délai
Tunnel CF do	HTTP 530/1033	systemctl --user restart	< 2 mi
Backend down	Connection refus	uvicorn main:app --port	< 5 mi
API source r	429	Backoff exponentiel auto	< 30s
API source d	Timeout 30s	Skip source, continuer ≥	Auto
Build fronte	404 JS/CSS	cd frontend && npm run b	< 2 mi
Double pref	/stock-analysis/	Accéder via sa.cedlabusa	Immédi
Port 8780 oc	Address already	Isof -i :8780 → kill <PI	< 1 mi
Mémoire WSL	OOM kill	wsl --shutdown + redémar	< 3 mi
Crash pipeli	Erreur 500	Supprimer analyse partie	—

9.3 Vérification post-restauration

```
# 1. Backend health
curl -s -w "%{http_code}" https://sa.cedlabusa.net/api/health

# 2. Frontend reachable
browser_navigate → https://sa.cedlabusa.net

# 3. Analyse test
saisir "AAPL" → lancer analyse → vérifier PDF + ZIP
```

10. Contraintes

Le pipeline opère dans un environnement contraint (APIs gratuites, WSL2, Cloudflare Tunnel). Ces contraintes sont documentées pour anticiper les limitations.

ID	Contrainte	Type	Impact
C-001	yfinance ~5 req/s infor	Technique	Délai entre tickers batch
C-002	Finnhub free tier (60 r	Source	Limitation collecte news/e
C-003	Alpha Vantage free (25	Source	Transcripts limités
C-004	Tavily API (1000 req/mo	Source	IR enrichment limité
C-005	Cloudflare Tunnel expos	Sécurité	Auth X-API-Key obligatoire
C-006	WSL2 backend uniquement	Déploieme	Pas de containerisation, p
C-007	React buildé en bundle	Frontend	Cache-busting obligatoire
C-008	Seeking Alpha HTML scra	Source	Fragile, dépend structure

11. Risques et décisions

11.1 Risques identifiés

Medium RSK-001 — API Seeking Alpha bloque le scraping

Risque : L'API Seeking Alpha peut bloquer le scraping HTML à tout moment, rendant les transcripts indisponibles.

Mitigation : Fallback Alpha Vantage + Tavily pour les transcripts. Diversification des sources.

Low RSK-002 — yfinance change l'API

Risque : L'API non documentée de yfinance peut changer sans préavis, cassant la collecte de données fondamentales.

Mitigation : Finnhub + EDGAR en fallback pour les données critiques. Monitoring des changements d'API.

Low RSK-003 — Double bookkeeping financier

Risque : Les données enrichies par SEC EDGAR mettaient à jour financials (modèle Pydantic) mais pas fin (dict utilisé par le scorer), produisant des scores erronés.

Mitigation : Fixé (commit 3cf8f9b) : sync automatique EDGAR → financials ET fin. Test de régression en place.

Low RSK-004 — Quick tunnel au lieu de named tunnel

Risque : Le tunnel Cloudflare éphémère (quick) ne sert pas le domaine stable sa.cedlabusa.net.

Mitigation : Auto-recovery détecte le quick tunnel et bascule automatiquement sur le named tunnel.

Low RSK-005 — Indentation bug PDF renderer

Risque : L'ajout d'une fonction helper après la fonction render avec un corps indenté de 4 espaces peut absorber le code de fermeture dans la fonction helper, rendant le renderer silencieusement None.

Mitigation : Fixé (commit af2b3df) : toutes les fonctions helper définies AVANT la fonction render. Linter configuré.

Medium RSK-006 — Mémoire WSL insuffisante

Risque : WSL2 a une mémoire limitée. Au-delà de 3 batchs simultanés, risque de OOM kill par Windows.

Mitigation : Batch limité à 10 tickers max. Nettoyage après chaque analyse. Surveillance mémoire.

11.2 Décisions d'architecture

- ADR-001 : Stack Python/FastAPI + React/Vite + ReportLab + Cloudflare Tunnel — choisi pour la rapidité de développement et le déploiement sans infrastructure cloud.
- ADR-002 : Scoring rules-based (40 pts, 6 catégories) plutôt que ML — choisi pour l'auditabilité et la transparence. Chaque point du score est traçable jusqu'à sa source.

12. Critères d'acceptation globaux

ID	Critère	Méthode	Seuil
GA-001	Analyse NVDA complète	Chronomètre	< 5 min
GA-002	PDF ≥ 10 pages, émojis	Audit visuel	100% des pages
GA-003	ZIP contient PDF + anal	Extraction manuelle	3 fichiers min
GA-004	API health retourne 200	curl -s -w "%{http_c	200
GA-005	Tests pipeline passent	pytest tests/ -v	0 échec
GA-006	Aucune donnée inventée	Audit sources vs PDF	0 invention
GA-007	Frontend accessible	browser_navigate	Page load < 5s
GA-008	Feedback enregistré	POST /api/feedback →	Message horodaté
GA-009	Erreur ticker invalide	Saisir ZZZZYX	Message erreur <
GA-010	Rate limit géré	Simuler 429 yfinance	Retry auto, skip

13. Glossaire

Ticker	Symbole boursier (ex: AAPL, NVDA, MSFT) — 1 à 5 caractères, uppercase.
Deep-dive	Analyse narrative enrichie générée par LLM à partir des données financières collectées.
Scoring	Note sur 40 points répartis en 6 catégories, déterminant la recommandation BUY/HOLD/SELL.
BUY	Recommandation d'achat — score ≥ 28/40.
HOLD	Recommandation de conservation — score entre 18 et 27/40.
SELL	Recommandation de vente — score < 18/40.
INSUFFISANT	Pas de recommandation — moins de 3 sources de données valides.
EDGAR	Electronic Data Gathering, Analysis, and Retrieval — base de dépôts SEC (USA).
Callout box	Encadré coloré dans le PDF mettant en valeur une information clé (bleu #2563EB).
Quick tunnel	Tunnel Cloudflare éphémère sans nom de domaine stable (debug uniquement).
Named tunnel	Tunnel Cloudflare permanent avec nom de domaine configuré (production).
CacheBustingStaticFiles	Classe FastAPI qui ajoute Cache-Control: no-cache aux fichiers statiques.
Finnhub	API financière US gratuite (60 req/min) — prix, secteurs, market cap, actualités.
Seeking Alpha	Plateforme d'analyse financière — transcripts de earnings calls (scraping HTML).
Tavily	API de recherche web optimisée pour AI agents (1000 req/mois gratuites).
Alpha Vantage	API financière gratuite (25 req/jour) — données fondamentales et transcripts.